

EDA 回归失败自动归因聚类期末汇报

Regression Failure Bucketing

汇报人：李师贤 2026 年 6 月 16 日

lbex 数据构建 + 官方差异诊断 + Trace/Completion 技术路线

汇报结构

- 数据制造
- 技术路线
- 未来思路


数据制造

数据制造：数据口径（按时间顺序）

期中（2026-05-19）前完成 old_fake 三批（Xcelium 工具链），期中后切换到 VCS 工具链完成 v1→v2 两版迭代。

数据来源（按时间）	规模	关键特征与作用
1. old_fake 三批（已废弃，保留作对照基准）	80+240+640=960 cases, 32 bugs, Xcelium	期中前完成。验证全链路；已不再用于训练，但保留为历史对照评估基准（后续表格中的 first/stage2/stage3 即指此数据）。
2. VCS stage1 v1	40 cases, 3 bugs, VCS + Verdi	期中后首版，切换到 VCS。暴露问题：regr.log 仅 1 条 mismatch，恒为 0/1，无 meta.csv。
3. stable official-like v2	24 cases, 4 bugs, VCS + Verdi	当前主力 。regr.log 含 ibex+spike 双行，5 分叉点，动态 matched/mismatch，有 meta.csv，每 bug 2 tests×3 seeds。
4. fixed official set1/set2	7+25 cases, 2026-06-01 更新	官方公开 benchmark，用于评估迁移差距。Alpha 提交验证： set1 BA=0.722, set2 BA=0.921 。

结论：四代数据逐步逼近官方分布，v2 在 regr.log 格式上已接近官方，sim.log 和失败类型仍需补强。



两套工具链

- Xcelium 23.09: old_fake 三代，已废弃。
- **VCS + Verdi + Spike**: v1/v2 official-format, 当前主力。
- VCS 产出 sim.log.gz + trace.log.gz。

输出

- regr.log (纯文本) + sim.log.gz + trace.log.gz。
- input.csv + golden.csv + meta.csv。
- 每 bug 2 tests × 3 seeds = 6 cases。

case 目录（官方格式）

- `case_1/regr.log`（纯文本）
- `case_1/sim.log.gz`（gzip 压缩）
- `case_1/trace.log.gz`（gzip 压缩）
- 目录 flat 结构，无 `cases/` 子目录

校验重点

- `input.csv`: Case, Regr Log, Sim Log, Trace Log。
- `golden.csv`: Case, Bug。
- 过滤环境失败: license、DPI、core dump 等。
- `validate_dataset.py`: **`num_errors = 0`**。

期中后共进行了两版 official-format 数据迭代。v1 暴露问题，v2 针对性改进。

维度	v1 (official_vcs_stage1)	v2 (stable_official_like)
规模	40 cases, 3 bugs	24 cases, 4 bugs
regr.log	约 3 行, 1 条 mismatch, 无 spike 对照	约 20 行, ibex + spike 双行对照 , 5 个分叉点
matched/mismatch	恒为 0/1	动态比例 (如 17 matched, 11176 mismatch)
meta.csv	无	有 (group/family/test/seed)
sim.log 状态	无明确结论	UVM TEST PASSED

核心改进：**regr.log 从单一 mismatch 条目变成完整的分叉序列，补上了 spike 对照。**

数据制造：v2 与官方 benchmark 的剩余差距

v2 的 regr.log 格式已接近官方，但 sim.log 和失败类型仍有三个关键差距需要下一版（v3）补齐：

维度	v2 现状	官方 benchmark
sim.log 结果	100% UVM TEST PASSED, 无 UVM_ERROR/FATAL	PASSED、FATAL、ASSERT X 态、timeout 混合
失败类型	100% cosim mismatch	mismatch + debug timeout + interrupt timeout + ASSERT
测试类型	仅随机测试 (rand_test / rand_instr), 无 directed	directed + random 混合 (debug_basic_test 等)

下一步 v3 目标：补齐 sim.log 中的 FAILED/FATAL/ASSERT 信号，引入 directed tests。

通过与官方 benchmark 的逐 case 对比，识别出三个系统性差异，直接指导了 v2 的改进方向和 v3 的规划。

诊断发现（对比官方 benchmark）

- 官方同一 bug 跨 test 表现不同（如 bug_107 的 15 个 case 分叉位置和失败阶段各异），old_fake 同类 bug 表现更均匀。
- 官方 debug/irq/CSR/ASSERT 信号占比远高于 old_fake，后者几乎纯 mismatch。
- 官方 set1 存在争议 case（case_5/9 sim/regr/trace 逐位相同但 gold 标注不同 bug），标签粒度更细。

对应造数据策略（v2 已执行，v3 规划中）

- v2：每 bug 覆盖 2 种 test + 3 seeds，模拟跨 test 表现差异。
- v3：补 directed tests（debug_basic_test 等）+ FAILED/FATAL/ASSERT 失败入口。
- v3：构造同一 bug 跨 mismatch 与 FAILED 的混合 case，增加分叉时机差异。

技术路线

技术路线：整体路径

阶段	做法	核心结论与数据
Baseline	Drain+TF-IDF/SVD64+Agglomerative cluster_factor=0.875	old_fake stage3 BA=0.779，稳定但仅利用浅层模板。
Pairwise 建模	21d pair 特征 + GBDT/MLP，学习 P(same_bug)	GBDT mean BA=0.796，超 concat baseline(+2.2pp)。
LLM Embedding	Nomic 768d 与 SVD64 拼接，权重 w=4.0	stage2 TNR 0.744→0.788(+4.4pp)，语义信号有效。
Dual LLM+Struct	双路 LLM(features+summary)+signals+focal MLP	mean BA 0.806→0.857(+5.1pp)，输入设计 > 堆模型规模。
Gated MLM	sigmoid gate+6 层残差 +L1 正则，294d pair 输入	7-dataset macro BA 0.813 vs 0.688 ，全 7 fold 超 residual。
Calibrated Blend	alpha=0.88，rt=1.15，et=1.00	0-9 mean BA= 0.869 ，0-19= 0.853 ，LODO= 0.860 。
Bridge-Edge	OOF 模型识别分片桥接边 → 辅助 BCE loss	好种子 BA~0.91(bug_107 修复)，坏种子崩溃，需稳定化。
Trace/Completion	Route A 52d trace 特征 / completion JSON 证据	VCS +5.2% BA，set2 -8.1%，需 dataset-aware gate。

技术路线：pairwise 算法 — 从规则到学习

核心思路：将”直接聚类日志”转为”学习两个 case 是否同源”。评估指标本身是 pairwise BA，直接优化更有效。

特征工程（294 维 pair 向量）

- deterministic SVD64 cosine / 欧氏距离
- 双路 LLM embedding
(features+summary) cosine
- token Jaccard (primary/sim/regr 分列)
- 结构化冲突信号：
same_primary_signature、
same_mismatch_type、same_op_pair、
same_fatal_file 等 14 个二值特征
- 计数特征：num_tokens 对数差分

5-seed half-split 对比（3 old_fake 数据集）

方法	first	stage2	stage3
det (SVD64)	0.767	0.745	0.760
LLM concat	0.785	0.769	0.768
pw_logistic	0.759	0.809	0.792
pw_gbdtd	0.752	0.831	0.804
pw_mlp	0.757	0.828	0.797

pw_gbdtd mean BA=0.796 (+2.2pp)。stage2 TNR 从 0.81

提升到 0.88 (+12pp)。

技术路线：Gated MLP — 期中后最大架构突破

GatedResidualMLP (`pairwise_neural_models.py`): 在 residual backbone 前加入 feature-wise sigmoid gate。

架构

- 输入：294 维 pair 向量
- Gate: $\text{Sigmoid}(\text{gate}(x)) \times x + \text{L1 正则}$
- Backbone: 6 层残差
[512,512,512,256,256,128]
- GELU + LayerNorm + Dropout
- Focal Loss ($\gamma=2.0$)

7-dataset LODO 对比 (seed-0)

数据集	Residual	Gated
first	0.7790	0.7914
stage2	0.7473	0.8036
stage3	0.7809	0.7985
VCS off.	0.5869	0.7428
stable	0.4880	0.6380
set1	0.7222	1.0000
set2	0.7146	0.9170
mean	0.6884	0.8130

结论：Gated MLP 在所有 7 个数据集上超过 Residual MLP, 0-9 seed macro BA **0.7581 vs 0.7194**。

技术路线： trace.log 的使用与实验结论

trace log 提供执行路径证据。6 月实验用三种方式测试 trace 使用边界。

用法	关键实验数据	当前判断
Trace Route A (52d 确定性特征)	VCS +5.2% BA / set2 -8.1%。CSR/trap 受益, mismatch 受噪声干扰。	数据集依赖性, 需 dataset-aware gate。
Trace Modality Dropout	7-domain LODO: first+5.9%/stage2+4.5%/set1-47.2 protection gate mean= 0.791 。	提升局部但严重破坏 set1, 需 teacher/gate 保护。
Anchor Trace Window	official-directed: w64 仅用 trace BA= 0.984 vs no_trace 0.590。	对特定风格有效, 适合作为诊断工具。
Trace 验证/Refine	0-9 trace refine mean BA +0.0005; veto_boost 引入 FP 净增 235。	当前不启用, 保留为事后复核用途。

结论： trace 有信号但不稳定， 不能作为全局默认特征。 下一步应做 dataset-aware gating。

技术路线： completion LLM — 专家证据抽取器

completion LLM 不负责聚类，不直接输出 bucket。它只做一件事：把 sim/regr 局部信号规范化成结构化 JSON 证据，供 selective expert 框架使用。

设计约束

- 每个 case 最多调用 1 次并缓存，不按 pair 调用
- 不发送 raw log lines、路径、地址、标识符
- 不发送 gold/meta/trace 或 bucket label
- 只 canonicalize 白名单枚举和布尔信号

输出：canonical evidence JSON

- mechanism / stage / mismatch_object
- state / trigger / evidence_tags

当前判断： completion 保留为 selective expert evidence，管线已通，gate 调优中。


第一轮实验： structured-completion (seed-0)

方法	stable	set1	set2
base (no LLM)	0.565	0.722	0.775
trace only	0.505	0.722	0.837
structured compl.	0.504	0.458	0.784
trace + compl.	0.565	0.556	0.634

结论：白名单枚举太粗 → false merge 增加 → 整体未超 base。

Raw-public caching 已启动，NVIDIA endpoint HTTP 429 限速。

技术路线：selective expert 框架



流程说明

- 1 base model 输出 pair 概率矩阵
- 2 difficulty score 筛选最高难度 ~15% 的 case
- 3 仅对高难 case 调用 trace/completion 专家
- 4 gate 融合 base 与 expert 概率
- 5 signed-graph 聚类产生最终 bucket

关键约束

- 专家不可用时 gate 权重严格为 0, base probability 保持不变
- gate 仅从 held-out training pairs 学习, 不读取目标 gold 标签
- 每个 episode 专家 case 最少 2 个、最多 20 个
- completion 缺配置/HTTP 错误/rate limit 时不阻断管线

当前推荐：no-trace calibrated blend

- BA: 0-9 headline **0.869**, 0-19 strict **0.853**, LODO **0.860**
- 架构: residual focal MLP + ensemble (logistic/GBDT/MLP 权重 0.20/0.40/0.40)
- 校准: alpha=0.88, rt=1.15, et=1.00

暂不默认启用

- trace direct concat / heuristic trace policy
- structured completion 直接融合
- 无保护的 expert probability

Alpha 提交验证 (2026-06-06)

- set1 (7 cases, k=2): **BA=0.722**, TPR=0.778, TNR=0.667, 5.1s
- set2 (25 cases, k=4): **BA=0.921**, TPR=0.957, TNR=0.885, 9.4s
- Alpha 时限 90s (公开 30s×3), 均大幅低于上限; Fallback 通过

架构候选: Gated MLP

- seed-0 macro BA: **0.813 vs residual 0.688** (+12.5pp)
- 0-9 seed macro BA: **0.758 vs residual 0.719** (+3.9pp)
- 未替换主因: set2 seed 方差大 (seed 0→0.917, seed 1-2→0.715), 0-9 inner calibration 未完成

未来思路

优先级	任务	目标
P0	补齐 v3 数据的失败类型	增加 debug timeout、interrupt timeout、ASSERT、FAILED (非 mismatch)，引入 directed tests。
P0	Gated MLP 替代 residual 成为新 backbone	完成 0-9 seed 稳定性 + inner calibration，替换当前 no-trace calibrated blend。
P0	Completion selective expert 接入	Smoke test 已通过，需调优 gate + teacher distillation。
P1	Bridge-Edge Mining 稳定化	好种子 bug_107 完全修复 (BA~0.91)，需 multi-seed OOF ensemble + quality gate。
P1	Trace Route A 的 dataset-aware gating	VCS 数据集受益 (+5.2% BA)，set2 受损 (-8.1%)，需按数据集类型决定是否启用。

未来思路：四条主线

数据主线

- v2 $\rightarrow$ v3: 补 debug/irq/CSR/timeout。
- 补 directed tests。
- 对齐官方 benchmark。

架构主线

- Gated MLP 替代 residual backbone。
- 多 seed ensemble。
- Inner calibration。

证据主线

- Trace Route A + Completion 统一为 selective expert evidence。
- Gate + teacher distillation 控制影响。
- 不直接输出 bucket。

评估主线

- 7-dataset LODO 持续评估。
- 对齐 B_20260601 新 benchmark 规则。
- 跨域泛化验证。

期中后已完成两条主线推进：**v1→v2 数据迭代**使自造数据格式对齐官方，**Gated MLP 架构突破**在 7-dataset LODO 中全胜 residual。

已经形成

official-format v1→v2 两版迭代 (VCS 工具链, golden.csv + .gz 压缩, regr.log 含 ibex+spike 双行对照); Alpha 提交 set1 BA=0.722 / set2 BA=0.921; Gated MLP 作为新 backbone 候选 (macro BA 0.7581)。

当前瓶颈

v2 失败类型仍单一 (缺 FAILED/FATAL/ASSERT); set2 bug_107 分片问题 (Bridge-Edge 方向正确但不稳定); trace/completion 的 gated 融合。

后续重点

v3 数据补齐失败类型 + directed tests; Gated MLP 0-9 seed 稳定性验证; Selective expert gate 调优; 评估对齐 B_20260601 新规则。

谢谢！

EDA 回归失败自动归因聚类

ICCAD 2026 Problem B